

Séries de TV: dados, qualidade e audiência

Pipeline analítico de episódios e avaliações IMDb no Databricks

Relatório do MVP

Ricardo César Santos Mendes Costa

Pós-graduação em Data Science & Analytics

Databricks · Unity Catalog · PySpark · Delta Lake

Nove séries · duas fontes por série · arquitetura medalhão

Sumário

1. Contextualização e objetivo	3
Perguntas de negócio	3
Escopo e interpretação	3
2. Coleta e fontes de dados	3
3. Plataforma, carga e pipeline	3–6
3.1 Evidências da plataforma e ingestão	4
3.2 Camadas e arquivos persistidos	5
4. Modelagem e Catálogo de Dados	6
5. Qualidade dos dados e decisões	6
6. Análise e resultados	7
7. Relação entre audiência e nota	7
8. Resultados em gráficos	8–10
8.1 Métricas por temporada e correlação	9
8.2 Variação de audiência e consistência	10
9. Dashboard no Databricks	11–13
9.1 Evolução por temporada e consistência	12
9.2 Modelo de dados e relacionamentos	13
10. Autoavaliação e aprendizados	14
11. Repositório e reprodução	14

Sumário de imagens

Figura 1 - Intervalo de exibição	8
Figura 2 - Episódios por série	8
Figura 3 - Média IMDb por série	8
Figura 4 - Média IMDb por temporada	9
Figura 5 - Audiência média por temporada	9
Figura 6 - Correlação entre audiência e nota	9
Figura 7 - Mudança de audiência por temporada	10
Figura 8 - Dispersão das notas IMDb	10
Figura 9 - Workspace Databricks do projeto	4
Figura 10 - Notebook principal no Git folder sincronizado	4
Figura 11 - Unity Catalog com schemas e tabelas Bronze	4
Figura 12 - Arquivos CSV no volume bronze.datafiles	5
Figura 13 - Tabelas criadas no schema Silver	5
Figura 14 - Tabelas analíticas criadas no schema Gold	5
Figura 15 - Visão geral do dashboard	11
Figura 16 - Comparação entre séries	11
Figura 17 - Evolução das notas e audiência por temporada	12
Figura 18 - Audiência, avaliação e consistência	12
Figura 19 - Modelo de relacionamentos entre datasets	13
Figura 20 - Relacionamentos e visualizações por série	13

1. Contextualização e objetivo

Este MVP transforma conjuntos públicos sobre episódios de nove séries de televisão em uma base analítica no Databricks. Gosto de séries e encontrei neste trabalho uma oportunidade de combinar esse interesse com práticas de Engenharia de Dados. O projeto percorre coleta, ingestão, avaliação da qualidade, transformação, reconciliação entre fontes e preparação de métricas.

O problema de negócio é comparar a trajetória e a recepção das séries a partir do intervalo entre datas de exibição, quantidade de episódios, avaliações IMDb e audiência média nos Estados Unidos. Também se investiga a associação linear entre audiência e nota nos episódios pareados com segurança.

Perguntas de negócio

- Qual série teve o maior intervalo entre a primeira e a última exibição registrada?
- Quais séries possuem mais e menos episódios nos dados analisados?
- Quais séries têm as maiores e menores notas médias no IMDb?
- Como a nota média IMDb varia entre temporadas?
- Como a audiência média nos Estados Unidos varia entre temporadas?
- Existe associação entre audiência e nota IMDb por episódio, dentro de cada série?

Escopo e interpretação

“Duração” é o intervalo entre a menor e a maior data encontrada, não o tempo de produção. A contagem segue a granularidade da fonte e pode tratar episódios especiais ou histórias em partes de forma diferente. A audiência é a registrada nos CSVs para os Estados Unidos. As conclusões são descritivas e limitadas aos nove conjuntos.

2. Coleta e fontes de dados

Encontrei os CSVs nas páginas públicas do usuário bcruise no Kaggle. Baixei e organizei arquivos de episódios e IMDb para cada série, 18 arquivos no total.

Enviei os CSVs ao volume do Unity Catalog `mvp_engdados.bronze.datafiles`. O notebook percorre os arquivos, identifica o tipo pelo sufixo, deriva `series_id` do prefixo e registra o caminho de origem e o horário de ingestão. Caminho: `/Volumes/mvp_engdados/bronze/datafiles/`.

Página geral: [kaggle.com/bcruise/datasets](https://www.kaggle.com/bcruise/datasets). Datasets utilizados:

Série	Dataset Kaggle
The Big Bang Theory	kaggle.com/datasets/bcruise/big-bang-theory-episodes
Brooklyn Nine-Nine	kaggle.com/datasets/bcruise/brooklyn-99-episode-data
Lost	kaggle.com/datasets/bcruise/lost-episodes
The Office	kaggle.com/datasets/bcruise/the-office-episodes-data
Friends	kaggle.com/datasets/bcruise/friends-episode-data
How I Met Your Mother	kaggle.com/datasets/bcruise/how-i-met-your-mother-episodes-data
Game of Thrones	kaggle.com/datasets/bcruise/game-of-thrones-episodes
Breaking Bad	kaggle.com/datasets/bcruise/breaking-bad-episode-data
The Walking Dead	kaggle.com/datasets/bcruise/the-walking-dead-episodes

Consulte os termos de licença nas páginas de origem antes de redistribuir os arquivos.

3. Plataforma, carga e pipeline

A implementação usa Databricks, Unity Catalog, PySpark e tabelas Delta. No catálogo `mvp_engdados` foram criados os schemas `bronze`, `silver` e `gold`, além do volume `bronze.datafiles`. O notebook completo está em github.com/RicCesar/mvp_engenharia_dados (NB_Final_Analise_Series.ipynb).

O Databricks foi sincronizado com o GitHub por Git folders. Como a configuração do workspace desabilitava o commit dos outputs, baixei o notebook executado e enviei-o ao repositório para preservar os resultados; os gráficos também foram exportados como imagens.

3.1 Evidências da plataforma e ingestão

As capturas documentam o ambiente Databricks, a integração com Git e o caminho dos arquivos até as camadas analíticas. Os CSVs foram enviados ao volume bronze.datafiles; as tabelas foram organizadas no Unity Catalog em Bronze, Silver e Gold.

Name	Type	Owner	Created at	Last updated at
Drafts	Folder	ricardocesar.smc@gmail.c...	Sep 23, 2026, 11:50 PM	Sep 23, 2026, 11:50 PM
mvp_engenharia_dados	Git folder	ricardocesar.smc@gmail.c...	Sep 25, 2026, 09:13 PM	Sep 25, 2026, 09:13 PM
Bakehouse Sales Starter Space	Genie agent	ricardocesar.smc@gmail.c...	Sep 19, 2026, 02:13 PM	Sep 19, 2026, 02:13 PM

Figura 9 - Workspace Databricks do projeto

Name	Type	Owner	Created at	Last updated at
.git	Folder	ricardocesar.smc@gmail.c...	Sep 25, 2026, 09:13 PM	Sep 25, 2026, 09:13 PM
Análise de Séries de TV	Dashboard	ricardocesar.smc@gmail.c...	Sep 27, 2026, 01:40 PM	Sep 27, 2026, 02:11 PM
NB_Final_Analise_Series	Notebook	ricardocesar.smc@gmail.c...	Sep 25, 2026, 09:49 PM	Sep 25, 2026, 11:46 PM
README.md	File	ricardocesar.smc@gmail.c...	Sep 25, 2026, 09:13 PM	-


Figura 10 - Notebook principal no Git folder sincronizado

Name	Owner	Created at	Popularity	Comment
episodes_raw	ricardocesar.smc@gmail.com	Sep 25, 2026, 10:08 PM	...	Dados brutos de episódios, L...
imdb_raw	ricardocesar.smc@gmail.com	Sep 25, 2026, 10:08 PM	...	Dados brutos de episódios e...

Figura 11 - Unity Catalog com schemas e tabelas Bronze

3.2 Camadas e arquivos persistidos

O volume mantém os CSVs de origem e as tabelas Delta registram as transformações aplicadas nas camadas Silver e Gold.



Name	Size	Last modified
big_bang_theory_episodes.csv	50.55 KB	3 days ago
big_bang_theory_imdb.csv	58.81 KB	3 days ago
breaking_bad_episodes.csv	4.45 KB	3 days ago
breaking_bad_imdb.csv	11.46 KB	3 days ago
brooklyn99_episodes.csv	12.46 KB	3 days ago
brooklyn99_imdb.csv	29.62 KB	3 days ago
friends_episodes.csv	26.54 KB	3 days ago

Figura 12 - Arquivos CSV carregados no volume bronze.datafiles




Table Name
episodes
episodes_imdb_matched
imdb

Figura 13 - Tabelas criadas no schema Silver




Table Name
audience_rating_correlation
audience_season_change
rating_consistency
season_metrics
series_metrics

Figura 14 - Tabelas analíticas criadas no schema Gold

Camada	Responsabilidade	Tabelas / saídas
Bronze	Leitura dos CSVs em texto, identificação de série, origem e instante de carga.	episodes_raw, imdb_raw
Silver	Tipagem, datas padronizadas, correções documentadas e pareamento seguro.	episodes, imdb, episodes_imdb_matched
Gold	Agregações por série e temporada e métricas analíticas.	Tabelas Delta para consulta e gráficos

A Bronze preserva a origem. A Silver aplica regras explícitas. Na Gold, fontes são agregadas separadamente antes de serem combinadas, evitando multiplicar registros.

4. Modelagem e Catálogo de Dados

O catálogo `mvp_engdados` organiza tabelas por etapa. A fonte de episódios contém temporada, título, data e audiência; IMDb contém notas, votos, título, data e numeração. A tabela pareada só relaciona registros com uma chave única em ambas as fontes. Comentários foram registrados no Unity Catalog para documentar finalidade e grão.

Tabela	Grão / finalidade	Principais colunas
bronze.episodes_raw	Uma linha por episódio de origem.	season, episode_num_in_season, episode_num_overall, title, directed_by, written_by, original_air_date, prod_code, us_viewers, series_id, _source_file, _ingested_at.
bronze.imdb_raw	Uma linha por registro IMDb.	season, episode_num, title, original_air_date, imdb_rating, total_votes, desc, series_id, _source_file, _ingested_at.
silver.episodes	Episódios tipados e padronizados.	Campos de episódios tipados, campos de origem raw, series_id, _source_file, _ingested_at e indicador da correção.
silver.imdb	Registros IMDb tipados.	series_id, season, episode_num, title, original_air_date, imdb_rating, total_votes, desc, valores raw e linhagem.
silver.episodes_imdb_matched	Episódio pareado com segurança.	series_id, episode_season, episode_number, imdb_season, imdb_episode_number, episode_title, air_date, us_viewers, imdb_rating, total_votes, match_method.
gold.series_metrics	Uma linha por série.	series_id, episode_count, season_count, first_air_date, last_air_date, duration_days, duration_years, audience_episode_count, avg_us_viewers, imdb_episode_count, avg_imdb_rating.
gold.season_metrics	Uma linha por série e temporada.	series_id, season, episode_count, audience_episode_count, avg_us_viewers, imdb_episode_count, avg_imdb_rating.
gold.audience_rating_correlation	Uma linha por série.	series_id, episode_count, pearson_correlation, avg_us_viewers, avg_imdb_rating.
gold.audience_season_change	Uma linha por série e temporada.	series_id, season, avg_us_viewers, previous_season_viewers, audience_change_pct.
gold.rating_consistency	Uma linha por série.	series_id, imdb_episode_count, avg_imdb_rating, rating_stddev, median_imdb_rating, min_imdb_rating, max_imdb_rating.

5. Qualidade dos dados e decisões

A Bronze continha 1.510 linhas de episódios e 1.495 registros IMDb. Foram verificadas quantidades por série, valores vazios, duplicidades, datas e domínios de notas, votos e audiência.

Achado	Evidência	Tratamento
Identificador na ingestão	Registros agrupados como datfiles.	Extração de series_id pelo prefixo do arquivo.
Valores ausentes	433 vazios em prod_code e 5 em us_viewers.	Mantidos nulos, sem imputação sem fonte justificável.
Referência na numeração	Valores como 6[98] não convertiam para inteiro.	Remoção da referência e try_cast; inválidos permanecem auditáveis.
Duplicidade em Lost	LA X - Part 2 e Everybody Loves Hugo apareciam como S6E12.	Sequência e IMDb confirmaram LA X - Part 2 como S6E2; correção apenas na Silver.
Datas divergentes	Formato ISO e datas textuais, como 13 Apr. 2010.	Parse com ambos os formatos e validação de datas inválidas.
Divergências entre fontes	Numeração, títulos e quantidades não coincidem sempre.	Registros preservados; pareamento requer série, título e data únicos.
Piloto não exibido	Unaired Pilot não é episódio exibido.	Excluído da média IMDb; registro de origem preservado.

Conversões tolerantes evitam interromper a pipeline por um valor inválido. Validações na Silver verificam datas, duplicidades restantes e domínios esperados. Uma consulta sem linhas indica que a regra testada não encontrou ocorrências.

6. Análise e resultados

As contagens vêm da fonte de episódios e as médias IMDb da fonte de avaliações; o piloto não exibido foi excluído. O intervalo é calculado pelas datas extremas. Cobertura e granularidade limitam comparações diretas.

Série	Episódios	Intervalo (anos)	IMDb médio
The Big Bang Theory	279	11,64	7,82
Breaking Bad	62	5,69	9,03
Brooklyn Nine-Nine	153	8,00	8,13
Friends	236	9,62	8,42
Game of Thrones	73	8,09	8,75
How I Met Your Mother	208	8,53	8,14
Lost	121	5,66	8,55
The Office	201	8,15	8,22
The Walking Dead	177	12,05	7,92

Respostas às perguntas

- Maior intervalo registrado: The Walking Dead, 12,05 anos; menor: Lost, 5,66 anos.
- Mais episódios: The Big Bang Theory, 279; menos: Breaking Bad, 62.
- Maior média IMDb: Breaking Bad, 9,03; menor: The Big Bang Theory, 7,82.
- Game of Thrones cai de 9,03 na temporada 7 para 6,43 na 8; Breaking Bad chega a 9,43 na temporada 5.
- A maior audiência média sazonal observada foi Friends, temporada 2, com cerca de 31,72 milhões nos EUA.

7. Relação entre audiência e nota

Pearson mede associação linear e foi calculado sobre episódios pareados com audiência e nota disponíveis. A amostra varia por série. Correlação não demonstra causalidade.

Série	Episódios válidos (n)	Pearson r
Breaking Bad	57	0,540
The Office	175	0,511
The Walking Dead	177	0,280
Friends	234	0,276
How I Met Your Mother	208	0,110
Brooklyn Nine-Nine	153	0,007
Lost	117	-0,002
The Big Bang Theory	279	-0,193
Game of Thrones	73	-0,431

Breaking Bad e The Office têm associações positivas moderadas nos dados observados; Game of Thrones, negativa. Brooklyn Nine-Nine e Lost ficam próximas de zero. A análise não controla época, composição do público ou número de votos. Também foram analisadas a variação percentual da audiência e a dispersão das notas.

8. Resultados em gráficos

Gráficos exportados dos resultados do notebook final. As observações destacam padrões sem atribuir causalidade.

Origem: Gold, métricas por série; datas extremas e duração observada.




Figura 1 - Intervalo de exibição

Ponto de atenção: The Walking Dead lidera com 12,05 anos; Lost e Breaking Bad ficam próximas de 5,7 anos.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, métricas por série; contagem de episódios.




Figura 2 - Episódios por série

Ponto de atenção: The Big Bang Theory tem 279 episódios, seguida por Friends (236). Breaking Bad tem 62, menor total.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, métricas por série; média e contagem de notas.




Figura 3 - Média IMDb por série

Ponto de atenção: Breaking Bad lidera com 9,03; The Big Bang Theory tem 7,82. As quantidades de notas disponíveis variam.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

8.1 Métricas por temporada e correlação

Origem: Gold, métricas por temporada; média da nota.




Figura 4 - Média IMDb por temporada

Ponto de atenção: Game of Thrones cai de 9,03 na temporada 7 para 6,43 na 8; Breaking Bad chega a 9,43 na temporada 5.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, métricas por temporada; audiência nos EUA.




Figura 5 - Audiência média por temporada

Ponto de atenção: Friends chega a 31,72 milhões na temporada 2. Breaking Bad mais que dobra na temporada final: 1,87 milhão na S4 para 4,32 milhões na S5.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, correlação por série; Pearson e amostra.




Figura 6 - Correlação entre audiência e nota

Ponto de atenção: Breaking Bad (0,540) e The Office (0,511) têm associações positivas mais fortes; Game of Thrones tem a mais negativa (-0,431).

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

8.2 Variação de audiência e consistência

Origem: Gold, variação percentual contra a temporada anterior.




Figura 7 - Mudança de audiência por temporada

Ponto de atenção: O pico positivo de Breaking Bad corresponde à alta da audiência média na temporada final. A primeira temporada não tem comparação anterior.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, consistência de notas; desvio padrão.




Figura 8 - Dispersão das notas IMDb

Ponto de atenção: A dispersão complementa a média: séries com médias próximas podem apresentar consistência diferente entre episódios.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

9. Dashboard no Databricks

Usei o Genie do Databricks como ponto de partida: descrevi os insights desejados e aproveitei a estrutura inicial sugerida para o dashboard. Depois refinei as visualizações e os dados apresentados, ajustando páginas, títulos, filtros e métricas para refletir as perguntas de negócio. O dashboard publicado reúne visão geral, comparação entre séries, evolução por temporada e audiência, avaliação e consistência.



Figura 15 - Visão geral do dashboard




Figura 16 - Comparação entre séries

9.1 Evolução por temporada e consistência

As páginas sazonais acompanham as médias de nota IMDb e audiência nos EUA; a visão de consistência complementa a leitura das médias com dispersão e correlação.




Figura 17 - Evolução das notas e audiência por temporada




Figura 18 - Audiência, avaliação e consistência

9.2 Modelo de dados e relacionamentos

Criei relacionamentos usando `series_id` como chave comum entre os datasets analíticos. O modelo conecta métricas por série às tabelas de temporada, variação de audiência, correlação e consistência. A cardinalidade deve acompanhar o grão de cada tabela: resumos por série têm uma linha por série, enquanto métricas sazonais podem ter várias.




Figura 19 - Modelo de relacionamentos entre datasets




Figura 20 - Relacionamentos e visualizações por série

10. Autoavaliação e aprendizados

O objetivo foi atingido: a pipeline integra ingestão rastreável, camadas Bronze, Silver e Gold, verificações de qualidade, modelagem no Unity Catalog e tabelas para responder às perguntas de negócio.

O trabalho uniu meu interesse por séries à prática de Engenharia de Dados. Apreendi a preservar a origem antes de corrigir dados, lidar com padrões diferentes de data, usar conversões tolerantes e investigar divergências entre fontes. O pareamento por título, data e unicidade mostrou por que a numeração sozinha não basta.

As limitações principais são cobertura desigual, diferenças editoriais entre fontes e audiência restrita aos CSVs. Como próximos passos, seria possível incluir metadados oficiais, definir regras para especiais e episódios duplos e automatizar testes de qualidade.

Usei o Codex do ChatGPT como apoio para desenvolver e refinar códigos. Revisei resultados e investiguei erros antes de adotar as transformações; a ferramenta não substitui validação e entendimento das regras.

11. Repositório e reprodução

Repositório público: github.com/RicCesar/mvp_engenharia_dados. Usei o Git folder do Databricks para sincronizar o trabalho com o GitHub. Como o workspace não permitia commitar outputs, baixei o notebook executado e enviei-o ao repositório para preservar as saídas; os gráficos foram exportados separadamente.

Para reproduzir: obtenha os CSVs no Kaggle, crie o catálogo mvp_engdados, os schemas bronze, silver e gold e o volume bronze.datafiles, envie os arquivos ao volume, abra NB_Final_Analise_Series.ipynb e execute as células na ordem. A execução exige permissões de leitura do volume e gravação nos schemas.