

Séries de TV: dados, qualidade e audiência

Pipeline analítico de episódios e avaliações IMDb no Databricks

Relatório do MVP

Ricardo César Santos Mendes Costa

Pós-graduação em Data Science & Analytics

Databricks · Unity Catalog · PySpark · Delta Lake

Nove séries · duas fontes por série · arquitetura medalhão

Sumário

1. Contextualização e objetivo	3
Perguntas de negócio	3
Escopo e interpretação	3
2. Coleta e fontes de dados	3
3. Plataforma, carga e pipeline	3
4. Modelagem e Catálogo de Dados	4
5. Qualidade dos dados e decisões	4
6. Análise e resultados	5
Respostas às perguntas	5
7. Relação entre audiência e nota	5
8. Resultados em gráficos	6
9. Autoavaliação e aprendizados	8
10. Repositório e reprodução	8

Sumário de imagens

Figura 1 - Intervalo de exibição	6
Figura 2 - Episódios por série	6
Figura 3 - Média IMDb por série	6
Figura 4 - Média IMDb por temporada	7
Figura 5 - Audiência média por temporada	7
Figura 6 - Correlação entre audiência e nota	7
Figura 7 - Mudança de audiência por temporada	8
Figura 8 - Dispersão das notas IMDb	8

O relatório cobre os critérios da atividade: objetivo, coleta, modelagem e catálogo, carga e pipeline, qualidade, análise, autoavaliação e apresentação visual.

1. Contextualização e objetivo

Este MVP transforma conjuntos públicos sobre episódios de nove séries de televisão em uma base analítica no Databricks. Gosto de séries e encontrei neste trabalho uma oportunidade de combinar esse interesse com práticas de Engenharia de Dados. O projeto percorre coleta, ingestão, avaliação da qualidade, transformação, reconciliação entre fontes e preparação de métricas.

O problema de negócio é comparar a trajetória e a recepção das séries a partir do intervalo entre datas de exibição, quantidade de episódios, avaliações IMDb e audiência média nos Estados Unidos. Também se investiga a associação linear entre audiência e nota nos episódios pareados com segurança.

Perguntas de negócio

- Qual série teve o maior intervalo entre a primeira e a última exibição registrada?
- Quais séries possuem mais e menos episódios nos dados analisados?
- Quais séries têm as maiores e menores notas médias no IMDb?
- Como a nota média IMDb varia entre temporadas?
- Como a audiência média nos Estados Unidos varia entre temporadas?
- Existe associação entre audiência e nota IMDb por episódio, dentro de cada série?

Escopo e interpretação

“Duração” é o intervalo entre a menor e a maior data encontrada, não o tempo de produção. A contagem segue a granularidade da fonte e pode tratar episódios especiais ou histórias em partes de forma diferente. A audiência é a registrada nos CSVs para os Estados Unidos. As conclusões são descritivas e limitadas aos nove conjuntos.

2. Coleta e fontes de dados

Encontrei os CSVs nas páginas públicas do usuário bcruise no Kaggle. Baixei e organizei arquivos de episódios e IMDb para cada série, 18 arquivos no total.

Enviei os CSVs ao volume do Unity Catalog `mvp_engdados.bronze.datafiles`. O notebook percorre os arquivos, identifica o tipo pelo sufixo, deriva `series_id` do prefixo e registra o caminho de origem e o horário de ingestão. Caminho: `/Volumes/mvp_engdados/bronze/datafiles/`.

Página geral: [kaggle.com/bcruise/datasets](https://www.kaggle.com/bcruise/datasets). Datasets utilizados:

Série	Dataset Kaggle
The Big Bang Theory	kaggle.com/datasets/bcruise/big-bang-theory-episodes
Brooklyn Nine-Nine	kaggle.com/datasets/bcruise/brooklyn-99-episode-data
Lost	kaggle.com/datasets/bcruise/lost-episodes
The Office	kaggle.com/datasets/bcruise/the-office-episodes-data
Friends	kaggle.com/datasets/bcruise/friends-episode-data
How I Met Your Mother	kaggle.com/datasets/bcruise/how-i-met-your-mother-episodes-data
Game of Thrones	kaggle.com/datasets/bcruise/game-of-thrones-episodes
Breaking Bad	kaggle.com/datasets/bcruise/breaking-bad-episode-data
The Walking Dead	kaggle.com/datasets/bcruise/the-walking-dead-episodes

Consulte os termos de licença nas páginas de origem antes de redistribuir os arquivos.

3. Plataforma, carga e pipeline

A implementação usa Databricks, Unity Catalog, PySpark e tabelas Delta. No catálogo `mvp_engdados` foram criados os schemas `bronze`, `silver` e `gold`, além do volume `bronze.datafiles`. O notebook completo está em github.com/RicCesar/mvp_engenharia_dados (NB_Final_Analise_Series.ipynb).

O Databricks foi sincronizado com o GitHub por Git folders. Como a configuração do workspace desabilitava o commit dos outputs, baixei o notebook executado e enviei-o ao repositório para preservar os resultados; os gráficos também foram exportados como imagens.

Camada	Responsabilidade	Tabelas / saídas
Bronze	Leitura dos CSVs em texto, identificação de série, origem e instante de carga.	episodes_raw, imdb_raw
Silver	Tipagem, datas padronizadas, correções documentadas e pareamento seguro.	episodes, imdb, episodes_imdb_matched
Gold	Agregações por série e temporada e métricas analíticas.	Tabelas Delta para consulta e gráficos

A Bronze preserva a origem. A Silver aplica regras explícitas. Na Gold, fontes são agregadas separadamente antes de serem combinadas, evitando multiplicar registros.

4. Modelagem e Catálogo de Dados

O catálogo `mvp_engdados` organiza tabelas por etapa. A fonte de episódios contém temporada, título, data e audiência; IMDb contém notas, votos, título, data e numeração. A tabela pareada só relaciona registros com uma chave única em ambas as fontes. Comentários foram registrados no Unity Catalog para documentar finalidade e grão.

Tabela	Grão / finalidade	Principais colunas
<code>bronze.episodes_raw</code>	Uma linha por episódio de origem.	<code>season</code> , <code>episode_num_in_season</code> , <code>episode_num_overall</code> , <code>title</code> , <code>directed_by</code> , <code>written_by</code> , <code>original_air_date</code> , <code>prod_code</code> , <code>us_viewers</code> , <code>series_id</code> , <code>_source_file</code> , <code>_ingested_at</code> .
<code>bronze.imdb_raw</code>	Uma linha por registro IMDb.	<code>season</code> , <code>episode_num</code> , <code>title</code> , <code>original_air_date</code> , <code>imdb_rating</code> , <code>total_votes</code> , <code>desc</code> , <code>series_id</code> , <code>_source_file</code> , <code>_ingested_at</code> .
<code>silver.episodes</code>	Episódios tipados e padronizados.	Campos de episódios tipados, campos de origem raw, <code>series_id</code> , <code>_source_file</code> , <code>_ingested_at</code> e indicador da correção.
<code>silver.imdb</code>	Registros IMDb tipados.	<code>series_id</code> , <code>season</code> , <code>episode_num</code> , <code>title</code> , <code>original_air_date</code> , <code>imdb_rating</code> , <code>total_votes</code> , <code>desc</code> , valores raw e linhagem.
<code>silver.episodes_imdb_matched</code>	Episódio pareado com segurança.	<code>series_id</code> , <code>episode_season</code> , <code>episode_number</code> , <code>imdb_season</code> , <code>imdb_episode_number</code> , <code>episode_title</code> , <code>air_date</code> , <code>us_viewers</code> , <code>imdb_rating</code> , <code>total_votes</code> , <code>match_method</code> .
<code>gold.series_metrics</code>	Uma linha por série.	<code>series_id</code> , <code>episode_count</code> , <code>season_count</code> , <code>first_air_date</code> , <code>last_air_date</code> , <code>duration_days</code> , <code>duration_years</code> , <code>audience_episode_count</code> , <code>avg_us_viewers</code> , <code>imdb_episode_count</code> , <code>avg_imdb_rating</code> .
<code>gold.season_metrics</code>	Uma linha por série e temporada.	<code>series_id</code> , <code>season</code> , <code>episode_count</code> , <code>audience_episode_count</code> , <code>avg_us_viewers</code> , <code>imdb_episode_count</code> , <code>avg_imdb_rating</code> .
<code>gold.audience_rating_correlation</code>	Uma linha por série.	<code>series_id</code> , <code>episode_count</code> , <code>pearson_correlation</code> , <code>avg_us_viewers</code> , <code>avg_imdb_rating</code> .
<code>gold.audience_season_change</code>	Uma linha por série e temporada.	<code>series_id</code> , <code>season</code> , <code>avg_us_viewers</code> , <code>previous_season_viewers</code> , <code>audience_change_pct</code> .
<code>gold.rating_consistency</code>	Uma linha por série.	<code>series_id</code> , <code>imdb_episode_count</code> , <code>avg_imdb_rating</code> , <code>rating_stddev</code> , <code>median_imdb_rating</code> , <code>min_imdb_rating</code> , <code>max_imdb_rating</code> .

5. Qualidade dos dados e decisões

A Bronze continha 1.510 linhas de episódios e 1.495 registros IMDb. Foram verificadas quantidades por série, valores vazios, duplicidades, datas e domínios de notas, votos e audiência.

Achado	Evidência	Tratamento
Identificador na ingestão	Registros agrupados como datfiles.	Extração de <code>series_id</code> pelo prefixo do arquivo.
Valores ausentes	433 vazios em <code>prod_code</code> e 5 em <code>us_viewers</code> .	Mantidos nulos, sem imputação sem fonte justificável.
Referência na numeração	Valores como 6[98] não convertiam para inteiro.	Remoção da referência e <code>try_cast</code> ; inválidos permanecem auditáveis.
Duplicidade em Lost	LA X - Part 2 e Everybody Loves Hugo apareciam como S6E12.	Sequência e IMDb confirmaram LA X - Part 2 como S6E2; correção apenas na Silver.
Datas divergentes	Formato ISO e datas textuais, como 13 Apr. 2010.	Parse com ambos os formatos e validação de datas inválidas.
Divergências entre fontes	Numeração, títulos e quantidades não coincidem sempre.	Registros preservados; pareamento requer série, título e data únicos.
Piloto não exibido	Unaired Pilot não é episódio exibido.	Excluído da média IMDb; registro de origem preservado.

Conversões tolerantes evitam interromper a pipeline por um valor inválido. Validações na Silver verificam datas, duplicidades restantes e domínios esperados. Uma consulta sem linhas indica que a regra testada não encontrou ocorrências.

6. Análise e resultados

As contagens vêm da fonte de episódios e as médias IMDb da fonte de avaliações; o piloto não exibido foi excluído. O intervalo é calculado pelas datas extremas. Cobertura e granularidade limitam comparações diretas.

Série	Episódios	Intervalo (anos)	IMDb médio
The Big Bang Theory	279	11,64	7,82
Breaking Bad	62	5,69	9,03
Brooklyn Nine-Nine	153	8,00	8,13
Friends	236	9,62	8,42
Game of Thrones	73	8,09	8,75
How I Met Your Mother	208	8,53	8,14
Lost	121	5,66	8,55
The Office	201	8,15	8,22
The Walking Dead	177	12,05	7,92

Respostas às perguntas

- Maior intervalo registrado: The Walking Dead, 12,05 anos; menor: Lost, 5,66 anos.
- Mais episódios: The Big Bang Theory, 279; menos: Breaking Bad, 62.
- Maior média IMDb: Breaking Bad, 9,03; menor: The Big Bang Theory, 7,82.
- Game of Thrones cai de 9,03 na temporada 7 para 6,43 na 8; Breaking Bad chega a 9,43 na temporada 5.
- A maior audiência média sazonal observada foi Friends, temporada 2, com cerca de 31,72 milhões nos EUA.

7. Relação entre audiência e nota

Pearson mede associação linear e foi calculado sobre episódios pareados com audiência e nota disponíveis. A amostra varia por série. Correlação não demonstra causalidade.

Série	Episódios válidos (n)	Pearson r
Breaking Bad	57	0,540
The Office	175	0,511
The Walking Dead	177	0,280
Friends	234	0,276
How I Met Your Mother	208	0,110
Brooklyn Nine-Nine	153	0,007
Lost	117	-0,002
The Big Bang Theory	279	-0,193
Game of Thrones	73	-0,431

Breaking Bad e The Office têm associações positivas moderadas nos dados observados; Game of Thrones, negativa. Brooklyn Nine-Nine e Lost ficam próximas de zero. A análise não controla época, composição do público ou número de votos. Também foram calculadas variação percentual da audiência e dispersão das notas.

8. Resultados em gráficos

Gráficos exportados dos resultados do notebook final. As observações destacam padrões dos dados sem atribuir causalidade.

Origem: Gold, métricas por série; datas extremas e duração observada.




Figura 1 - Intervalo de exibição

Ponto de atenção: The Walking Dead lidera com 12,05 anos; Lost e Breaking Bad ficam próximas de 5,7 anos.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, métricas por série; contagem de episódios.




Figura 2 - Episódios por série

Ponto de atenção: The Big Bang Theory tem 279 episódios, seguida por Friends (236). Breaking Bad tem 62, menor total.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, métricas por série; média e contagem de notas.




Figura 3 - Média IMDb por série

Ponto de atenção: Breaking Bad lidera com 9,03; The Big Bang Theory tem 7,82. As quantidades de notas disponíveis variam.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, métricas por temporada; média da nota.




Figura 4 - Média IMDb por temporada

Ponto de atenção: Game of Thrones cai de 9,03 na temporada 7 para 6,43 na 8; Breaking Bad chega a 9,43 na temporada 5.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, métricas por temporada; audiência nos EUA.




Figura 5 - Audiência média por temporada

Ponto de atenção: Friends chega a 31,72 milhões na temporada 2. Breaking Bad mais que dobra na temporada final: 1,87 milhão na S4 para 4,32 milhões na S5.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, correlação por série; Pearson e amostra.




Figura 6 - Correlação entre audiência e nota

Ponto de atenção: Breaking Bad (0,540) e The Office (0,511) têm associações positivas mais fortes; Game of Thrones tem a mais negativa (-0,431).

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, variação percentual contra a temporada anterior.




Figura 7 - Mudança de audiência por temporada

Ponto de atenção: O pico positivo de Breaking Bad corresponde à alta da audiência média na temporada final. A primeira temporada não tem comparação anterior.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

Origem: Gold, consistência de notas; desvio padrão.




Figura 8 - Dispersão das notas IMDb

Ponto de atenção: A dispersão complementa a média: séries com médias próximas podem apresentar consistência diferente entre episódios.

Fonte: saída exportada do notebook NB_Final_Analise_Series.ipynb.

9. Autoavaliação e aprendizados

O objetivo foi atingido: a pipeline integra ingestão rastreável, camadas Bronze/Silver/Gold, verificações de qualidade, modelagem no Unity Catalog e tabelas para responder às perguntas.

O trabalho uniu meu interesse por séries à prática de Engenharia de Dados. Aprendi a preservar a origem antes de corrigir dados, lidar com padrões diferentes de data, usar conversões tolerantes e investigar divergências entre fontes. O pareamento por título, data e unicidade mostrou por que a numeração sozinha não basta.

As limitações principais são cobertura desigual, diferenças editoriais entre fontes e audiência restrita aos CSVs. Como próximos passos, seria possível incluir metadados oficiais, definir regras para especiais e episódios duplos e automatizar testes de qualidade.

Usei o Codex do ChatGPT como apoio para desenvolver e refinar códigos. Revisei resultados e investiguei erros antes de adotar as transformações; a ferramenta não substitui validação e entendimento das regras.

10. Repositório e reprodução

Repositório público: github.com/RicCesar/mvp_engenharia_dados. Usei o Git folder do Databricks para sincronizar o GitHub. Como o workspace não permitia commitar outputs, baixei o notebook executado e enviei-o ao repositório para preservar as saídas; os gráficos foram exportados separadamente.

Para reproduzir: obtenha os CSVs no Kaggle, crie o catálogo mvp_engdados, os schemas bronze/silver/gold e o volume bronze.datafiles, envie os arquivos ao volume, abra NB_Final_Analise_Series.ipynb e execute as células na ordem. A execução exige permissões de leitura do volume e gravação nos schemas.